

# MindVLA-U1 : VLA与VA的能力差距在于接口设计

“语言、时序、连续控制怎么接在一起？解决接口问题，VLA才能同时胜任“看一想一说一做”，实现更强的泛化与规模上限

- 01 接口错位，导致信息损失与训练错配
- 现有VLA：离散Token→扩散去噪→控制，链路冗长且信息瓶颈重重
  - 信息在离散化与去噪中被压缩/破坏，难以保留精细几何与时序细节
  - 训练目标与推理接口不一致(teacher forcing vs.closed-loop 执行)
  - 结果：同等算力下，VA（仅视觉一动作）在闭环表现上更优
- 02 MindVLA-U1：端到端流式接口，统一表征，消除中间损耗
- 视觉、状态、语言、历史动作统一编码为流式Latent（continuous）
  - 单一流式序列直接驱动扩散策略头，无需离散Token与重投影
  - 流式因果建模+滑动窗口，天然对齐实时闭环与长时依赖
  - 更高信息保真度，更低延迟，更强泛化（场景/指令/长尾）
- 03 不牺牲语言与可解释性，保持可控与可用
- 语言指令以流式Latent注入
  - 动作头直接输出连续轨迹/控制序列，兼容主流执行器与规划模块
  - 具备更好的可控性（指令跟随、风格/速度/偏好）与安全性边界
  - 为scale-up（数据/模型/算力）提供更优的接口基础设施




Figure 1: AD capability radar

**8.20RFS** 在 RFS Benchmark 上取得最优 SOTA 表现

**7.87 TestRFS** 测试集 RFS 达到7.87

**~16 FPS @1B** 在1B参数规模下 推理速度约16 FPS

**2 diffusion steps** 仅需2步扩散，实现高效闭环控制

为什么 VA 强但不够：连续控制强，显式语义弱

长尾自动驾驶既需要 VA 的连续动作精度，也需要 VLA 的显式语义和语言接口。

|                                                                                                                 | VA<br>(视觉-动作)                         | Prior VLA<br>(先前视觉-语言-动作)         | MindVLA-U1<br>(统一视觉-语言-动作)         |
|-----------------------------------------------------------------------------------------------------------------|---------------------------------------|-----------------------------------|------------------------------------|
|  <b>连续动作控制</b><br>动作精度与稳定性     | ✔ <b>强</b><br>厘米级精度<br>低延迟 (~20-50ms) | ◐ <b>中</b><br>受离散化与解码限制<br>误差累积   | ✔ <b>强</b><br>连续控制 + 语义对齐<br>低延迟   |
|  <b>语言语义保留</b><br>显式语义与可解释性    | ● <b>弱</b><br>语义隐式<br>难以解释与组合         | ✔ <b>中</b><br>有语言条件<br>但语义弱、对齐浅   | ✔ <b>强</b><br>显式语义表征<br>可解释、可组合    |
|  <b>流式连续性</b><br>长时序与状态连贯      | ✔ <b>强</b><br>端到端流式<br>长时序稳定          | ◐ <b>中</b><br>分段 / 离散序列<br>易漂移    | ✔ <b>强</b><br>统一流式建模<br>状态连贯、抗漂移   |
|  <b>自适应计算</b><br>按需计算与资源效率   | ✔ <b>强</b><br>计算路径短<br>高效低延迟          | ● <b>弱</b><br>固定长度 / 结构<br>计算冗余   | ✔ <b>强</b><br>按需激活与早退<br>更高资源效率    |
|  <b>语言到动作控制</b><br>指令跟随与任务泛化 | ● <b>弱</b><br>需额外规则 / 工程<br>泛化受限      | ◐ <b>中</b><br>可跟随简单指令<br>复杂组合能力不足 | ✔ <b>强</b><br>自然语言接口<br>复杂指令与组合泛化强 |

核心洞察



**VA 的强项：**  
厘米级控制与低延迟

- 端到端连续控制，动作精度高
- 低延迟、流式稳定，适合实时驾驶



**VLA 的缺口：**  
语义显式化与  
可组合长尾理解

- 语义隐式或对齐不足，难以解释
- 长尾场景依赖显式语义与组合能力
- 缺少自然语言到动作的通用接口



**MindVLA-U1 同时补齐两端：**  
连续控制 + 显式语义 + 语言接口

# 现有 VLA 的三类接口错配，解释了 precision floor 和 chunk discontinuity

性能差距来自接口层，而不是语言模型本身。



## 接口修正方向（合成）



### 1. continuous action

直接输出连续动作，消除量化与映射误差，突破 precision floor



### 2. streaming memory

流式记忆与状态传递，替代固定 chunks，消除冗余与边界割裂



### 3. Intent-CFG

基于意图的条件生成，引入可度量语言到动作的控制路径






### 4. fast/slow context management

快/慢双通道上下文管理，平衡近期细节与长期记忆，提升效率与稳定性



# 统一共享backbone：语言保持 AR，动作保持连续，两者共享同一表示

关键：action token 进入同一 backbone 的 self-attention



## Prior VLA (主流做法)



### 离散化动作 token

- 动作离散化为离散 token
- 表达受限、精度受限



### 独立动作专家 (Separate Expert)

- 动作走独立专家或分支
- 难以与语言共享表示与梯度



### 分块/分段时间建模

- Chunked 或窗口式训练
- 长程依赖与连续性受限



## MindVLA-U1 (统一共享骨干)



### 语言保持 AR (离散)

- 自回归文本, 语义连贯
- 指令遵循与世界知识强



### 动作保持连续 (Flow)

- Flow-matching 生成连续轨迹
- 平滑、精细、可微可优化



### 共享表示 (同一 backbone)

- action token 进入同一 self-attention
- 统一优化, 效果更强, 效率更高

# Flow-matching action head：用连续扩散式轨迹绕开离散 token 精度底板

动作输出形式必须尊重控制问题本身。

1. 核心思想（简化公式）

$$x_t = t\varepsilon + (1 - t)x_0$$

- 将干净轨迹  $x_0$  与噪声  $\varepsilon$  在线性插值，构造任意时间  $t \in [0, 1]$  的中间状态  $x_t$ 。
- 直接在连续时间上建模，不依赖离散 token 序列与量化。

2. 训练与推理范式



预测 velocity field, ODE/Euler 积分恢复轨迹


- 模型预测速度场  $v_\theta(x_t, t)$ ，近似真实 velocity  $v^*(x_t, t) = \frac{dx_t}{dt}$ 。
- 通过 ODE:  $\frac{dx_t}{dt} = v_\theta(x_t, t)$  进行数值积分（Euler），从噪声端（ $t=1$ ）积分到数据端（ $t=0$ ），得到连续轨迹  $x_0$ 。

3. 直观过程（概念图）

Noise

Velocity Field

Continuous Trajectory



4. 关键参数（与 headline 一致）

 5s horizon

 20 waypoints

 4Hz

 2 Euler steps at inference

5. 重要说明 /Caveat

Figure 6 用 5 steps 展示过程；headline 推理使用 2 steps





Figure 6: **Flow-matching denoising over 5 Euler steps** on one WOD-E2E frame (BEV: ego forward + X, lateral + Y) to better demonstrate the denoising process than 2 steps. Green: GT future; gray: past; blue: predicted trajectory after each denoise step. The Gaussian noise input that precedes Step 1 is not shown.

# Streaming Memory：把时序上下文从“多帧堆 token”改成“可学习 FIFO 状态”

时序建模的关键是 **bounded compute+ framewise continuity**。



消融对比 (Table 6 关键结果复盘)

| 方法                          | RFS (%) ↑   | 25s 序列 ADE (m) ↓ |
|-----------------------------|-------------|------------------|
| Chunk-wise single frame     | 7.69        | 1.54             |
| Chunk-wise + image sequence | 7.61        | 1.52             |
| Streaming no memory         | 7.73        | 1.51             |
| <b>Streaming + memory</b>   | <b>7.83</b> | <b>1.50</b>      |

## 结果解读

- Streaming + memory 在 RFS 与 25s ADE 上均取得最佳表现;
- 相较于仅 Streaming (无 memory), RFS 提升 +0.10, 25s ADE 降低 0.01m;
- 在相同计算预算下, 有限状态 (bounded memory) 带来可观的长时一致性收益。

## Streaming Memory 机制概览 (每个时刻 t)


### 1 Read memory with SE(2) motion alignment

- 将上一时刻的记忆 tokens  $M_{t-1}$  按相机/ego 运动做 SE(2) 对齐
- 得到对齐后的记忆  $\hat{M}_{t-1}$  供当前读取




### 2 Forward current multi-view frame + compact memory

- 将当前多视图帧  $V_t$  与对齐后的记忆  $\hat{M}_{t-1}$  一起输入模型
- 输出当前预测  $\hat{Y}_t$  (如占据/轨迹/规划)



### 3 Write refreshed memory tokens and evict oldest FIFO entry


- 由当前输出/隐藏态生成新的记忆 tokens  $M_t^{new}$
- 插入到队尾, 同时移除最老的条目 (FIFO)
- 得到更新后的记忆  $M_t$  (固定长度 N)





# Intent-CFG：第一次把 language-side intent 变成可测的连续动作控制信号


语言通过CFG改变action diffusion




**Table 3. 不同意图来源对 WOD-E2E 基准的影响 (RFS  $\uparrow$ )**

| 意图来源 (Intent Source)                          | RFS ( $\uparrow$ ) |
|-----------------------------------------------|--------------------|
| No intent (无意图)                               | 7.83               |
| Trajectory-derived (轨迹推导)                     | 7.81               |
| GT-supplied (人工提供 GT)                         | 7.83               |
| NTP-predicted Intent-CFG (NTP-预测的 Intent-CFG) | 7.92 (+0.09)       |

RFS (越高越好)




(a) Deployed: WOD-E2E 3-class intent + uncond.



(b) Extended: MindLabel 20-class intent + uncond.

# Fast/Slow + MoT : 同一 checkpoint 同时支持语义慢思考和动作快反射

VLA的实时性问题可以被架构化拆解



| 配置                 | RFS ↑ |
|--------------------|-------|
| Dense              | 7.83  |
| +MoT {V,L,M,S}+{A} | 8.01  |
| +MoT {V,L}+{M,S,A} | 7.92  |

**vqa\_first**  
V L M S A  
先慢 (VQA)  
后快 (Action)

**vqa\_only**  
V L M S  
仅慢路径  
(VQA)

**action\_first**  
M S A V L  
先快 (Action)  
后慢 (VQA)

**action\_only**  
M S A  
仅快路径  
(Action)



实验结果：MindVLA-U1 在WOD-E2E上关闭 VLA-VA planning gap  
并在val RFS 超过 human reference

架构收益最终反映到 open-loop planning 质量。

Table 1: WOD-E2E *validation split*. Methods grouped as VA / VLA / MindVLA-U1 (Ours), with the real-human-driver reference (logged GT trajectory scored under the same RFS metric) listed for comparison. **AD-PT**: external autonomous-driving pretraining (✓ yes, × no, ? not reported). *L B/R*: VQA BLEU-4 / ROUGE-L. **Bold / underline** = best / second-best per column among VLA + Ours.

| Method                                                   | Backbone                     | AD-PT | L B/R↑             | RFS-GT ADE 3/5↓           | RFS-matched ADE 3/5↓ | RFS↑              |
|----------------------------------------------------------|------------------------------|-------|--------------------|---------------------------|----------------------|-------------------|
| <b>VA Methods</b>                                        |                              |       |                    |                           |                      |                   |
| VAD [2]                                                  | ImageNet vision encoder [55] | ×     | —                  | 3.19 / 5.81               | —                    | 4.45              |
| UniAD [1]                                                | ImageNet ViT [55]            | ×     | —                  | 6.50 / 10.81              | —                    | 5.78              |
| RAP-DINO [11]                                            | DINOv3-H [56]                | ✓     | —                  | 0.97 / 2.20               | —                    | 7.91              |
| <b>VLA Methods (action-only at inference)</b>            |                              |       |                    |                           |                      |                   |
| Poutine-Base [22]                                        | Qwen2.5-VL-3B [33]           | ✓     | —                  | 1.27 / 2.94               | —                    | <u>8.12</u>       |
| <b>Real human driver (logged trajectory, RFS-scored)</b> |                              |       |                    |                           |                      |                   |
| Human Driver [22]                                        | —                            | —     | —                  | —                         | —                    | 8.13              |
| <b>MindVLA-U1 (Ours)</b>                                 |                              |       |                    |                           |                      |                   |
| MindVLA-U1                                               | Qwen3-VL-2B                  | ×     | 0.30 / 0.49        | 0.92 / 2.14               | 0.50 / 1.05          | 7.83              |
| MindVLA-U1 + Intent-CFG                                  | Qwen3-VL-2B                  | ×     | <b>0.31 / 0.52</b> | <b>0.86</b> / 2.13        | <b>0.47</b> / 1.07   | 7.92 <sup>1</sup> |
| MindVLA-U1 + MoT                                         | Qwen3-VL-2B                  | ×     | <u>0.30 / 0.51</u> | <u>0.89</u> / <b>2.11</b> | <u>0.49</u> / 1.05   | 7.92              |
| MindVLA-U1 + RL                                          | Qwen3-VL-2B [34]             | ×     | —                  | 1.01 / 2.28               | 0.51 / <b>1.03</b>   | <b>8.20</b>       |

Table 2: WOD-E2E *official test split*. Conventions as in Table 1.

| Method                                        | Backbone                    | AD-PT | RFS-GT ADE 3/5↓    | RFS↑        |
|-----------------------------------------------|-----------------------------|-------|--------------------|-------------|
| <b>VA Methods</b>                             |                             |       |                    |             |
| ViT-Adapter-GRU                               | n/r                         | ?     | 1.20 / 2.70        | 7.50        |
| Swin-Trajectory                               | Swin Transformer [57]       | ?     | 1.21 / 2.81        | 7.54        |
| DiffusionLTF                                  | DiffusionDrive [9]          | ?     | 1.36 / 2.98        | 7.72        |
| UniPlan (DiffusionDrive)                      | DiffusionDrive [9]          | ?     | 1.31 / 2.99        | 7.69        |
| <b>VLA Methods (action-only at inference)</b> |                             |       |                    |             |
| Open-LLaMA                                    | LLaMA-Vision [58]           | ?     | 1.31 / 3.22        | 7.43        |
| NaiveEMMA                                     | Gemini [59]                 | ×     | 1.32 / 3.02        | 7.53        |
| AutoVLA [19]                                  | Qwen2.5-VL-3B [33]          | ✓     | 1.35 / 2.96        | 7.56        |
| dVLM-AD [49]                                  | LLaDA-V [60] + SigLIP2 [61] | ✓     | 1.29 / 3.02        | 7.63        |
| HMVLM [62]                                    | Qwen2.5-VL-3B [33]          | ?     | 1.33 / 3.07        | 7.74        |
| <b>MindVLA-U1 (Ours, Language-preserving)</b> |                             |       |                    |             |
| MindVLA-U1                                    | Qwen3-VL-2B                 | ×     | 1.16 / 2.67        | 7.77        |
| MindVLA-U1 + RL                               | Qwen3-VL-2B [34]            | ×     | <b>1.09 / 2.66</b> | <b>7.87</b> |



核心结果 (KPI)

1 Val: MindVLA-U1 + RL

**8.20 RFS**

vs Human Driver 8.13

2 Test: MindVLA-U1 + RL

**7.87 RFS**

3 Test ADE:

**1.09 / 2.66 m**

4 No external AD pretraining in U1 rows

# 延迟拆解：慢不是因为 backbone 必然慢，而是 AR answer decoding 太贵

fast path 的工程空间明确，约 1B scale 已接近 VA FPS。






Table 5: Inference latency and throughput on WOD-E2E val (bs= 1, 1× H200). *Top*: per-stage timing of MindVLA-U1 dense (Qwen3-VL-2B) under the slow path (vqa\_first\_decoding); bracket codes — *V*: visual, *L*: language prompt (*Q*: VQA question), *A*: decoded answer, Act: noisy action, *M*: memory. *Bottom*: throughput across slow/fast inference paths sharing one set of weights, with RAP-DINO [11] as the strongest VA reference; the InternVL-2 1B row reports the same fast configuration at ~1B scale matched to RAP. **Bold** = recommended Pareto points.

| Configuration                                                                                                       | Latency↓  | FPS↑         | VRAM↓    | RFS↑        |
|---------------------------------------------------------------------------------------------------------------------|-----------|--------------|----------|-------------|
| <b>Stage-level timing</b> (Qwen3-VL-2B); bracket lists tokens processed per stage.                                  |           |              |          |             |
| Prefix embedding [ <i>V+L+M</i> , ≈ 624 tok; vision + past-state + text embed]                                      | ~30 ms    | —            | —        | —           |
| VQA prefilling [ <i>V+L+M</i> , ≈ 624 tok; prefill for VQA decoding]                                                | ~40 ms    | —            | —        | —           |
| VQA decoding [ <i>A</i> : ≈ 81 tok, autoregressive at 30.4 ms/tok]                                                  | ~2,450 ms | —            | —        | —           |
| Action diffusion, 1 Euler step [Act: ≈ 20 tok appended to <i>V+L+M+Q+A</i> ]                                        | ~38 ms    | —            | —        | —           |
| Action diffusion, 2 Euler steps [Act: ≈ 20 tok appended to <i>V+L+M+Q+A</i> ]                                       | ~74 ms    | —            | —        | —           |
| <b>End-to-end throughput</b> of MindVLA-U1 (Qwen3-VL-2B Dense, No Intent); compared with best-performing VA models. |           |              |          |             |
| RAP-DINO [11] (VA, ~0.88B)                                                                                          | 57 ms     | 17.68        | —        | 7.91        |
| MindVLA-U1 (InternVL-2 1B, template QA, 2 steps)                                                                    | 64 ms     | <b>15.55</b> | 2,478 MB | <b>7.78</b> |
| MindVLA-U1 (vqa_first_decoding, no intent, 2 steps)                                                                 | 2,594 ms  | 0.39         | 5,431 MB | 7.83        |
| MindVLA-U1 (action_only, 2 steps)                                                                                   | 103 ms    | 9.70         | 5,412 MB | 7.74        |
| MindVLA-U1 (vqa_first_fast, template QA, 2 steps)                                                                   | 108 ms    | <b>9.26</b>  | 5,412 MB | <b>7.82</b> |
| MindVLA-U1 (vqa_first_fast, template QA, 1 step)                                                                    | 63 ms     | 15.92        | 5,412 MB | 7.67        |



Scaling 与语言质量解耦：规划质量不简单随 VLM 参数单调增长，也不等于表面语言流畅度

不能只堆 backbone；要同时看数据、动作头、训练 schedule 和评价闭环。



2B 模型：指令微调 (Instruct) vs 基座 (Base)

| 模型 (2B)         | BLEU ↑ | ROUGE-L ↑ | RFS (越高越好) |
|-----------------|--------|-----------|------------|
| 指令微调 (Instruct) | 0.27   | 0.48      | 7.94       |
| 基座 (Base)       | 0.12   | 0.29      | 7.91       |

语言流畅度下降约 2×，规划 RFS 基本保持

Table 8: VLM backbone scaling on WOD-E2E val: identical architecture, data, and schedule, only the Qwen3.5-VL size varied. **Bold** = best per column, underline = second-best.

| Backbone                                | L B/R↑             | RFS-GT ADE 3/5↓    | RFS-matched ADE 3/5↓ | RFS↑        |
|-----------------------------------------|--------------------|--------------------|----------------------|-------------|
| Instruction-tuned VLM, default schedule |                    |                    |                      |             |
| Qwen3.5-VL 0.8B                         | 0.27 / 0.48        | 0.85 / 2.04        | 0.48 / 1.07          | 7.81        |
| Qwen3.5-VL 2B                           | 0.27 / 0.48        | 0.85 / 2.04        | 0.48 / 1.07          | <b>7.94</b> |
| Qwen3.5-VL 4B                           | 0.28 / 0.48        | 0.85 / <u>2.03</u> | 0.47 / 1.04          | 7.86        |
| Qwen3.5-VL 9B                           | <b>0.28 / 0.49</b> | 0.88 / 2.09        | <u>0.47</u> / 1.04   | 7.84        |
| Base VLM (no instruction tuning)        |                    |                    |                      |             |
| Qwen3.5-VL 2B (base)                    | 0.12 / 0.29        | 0.85 / 2.08        | 0.48 / 1.06          | 7.91        |
| Qwen3.5-VL 4B (base)                    | 0.13 / 0.30        | 0.86 / 2.05        | 0.47 / 1.03          | 7.86        |
| Extended training schedule              |                    |                    |                      |             |
| Qwen3.5-VL 9B (200 ep)                  | 0.28 / 0.48        | <b>0.87 / 2.05</b> | <b>0.46 / 1.00</b>   | <u>7.91</u> |

四大关键混杂因素 (confounds)

1 训练 Schedule

训练步数 / epoch / 学习率策略显著影响 RFS。

2 数据规模与质量

任务分布、开放词汇覆盖与标注质量决定上限。

3 动作接口容量

动作空间设计、离散化粒度与解析能力影响可表达性。

4 开环评价指标

RFS (开环) 与语言指标并非同一目标，不能互相替代。



# 总结：MindVLA-U1 证明可以通过统一流式接口填上VLA-VA gap

**Contributions**：一套把语义理解、连续动作、时序记忆和快慢执行统一起来的 VLA 架构范式。

1



**Unified shared backbone:**  
AR language + continuous flow action

- 单一 Transformer 骨干，统一建模语言 token 与连续动作 token。
- AR 流式解码，语言与动作同一序列空间，天然对齐、可微可扩展。

2



**Streaming Memory:**  
framewise stream + FIFO compact state

- 逐帧流式输入，持续更新隐藏状态。
- FIFO 紧凑记忆，仅保留必要历史，兼顾长程依赖与计算开销。

3



**Intent-CFG:**  
measurable language-to-action control

- 将语言意图显式注入为可控 CFG。
- 提供可度量的强度与时机控制，实现语言到动作的可测、可调、可解释映射。

4



**Fast/Slow MoT:**  
same checkpoint for slow semantic reasoning and fast action control

- 单一模型权重，通过推理时调度实现快慢解耦。
- 提速通道负责语义推理，快速通道负责动作控制，统一执行、无额外训练。




Figure 7: **Foundation architecture vision.** Three-stage generalization of the two-group MoT (§2.1, §F.1): perception, cognitive (context-group experts), and action (action-group experts). Highlighted: populated in MindVLA-U1; grey: extension slots on the same shared K/V pool.



局限性



**Open-loop only**  
仅为开环评估，未涉及闭环交互与在线纠错。



**Single benchmark WOD-E2E**  
评估集中于 WOD-E2E，泛化到其他任务/数据集仍待验证。



**No definitive scaling law**  
未给出确定性的缩放定律结论。



**Partial MindLabel use**  
MindLabel 管线仅部分使用，数据规模与覆盖范围有限。